STA607. Series de Tiempo

Joaquín Martínez*

30 de septiembre de 2026

1. Estacionariedad

Proyectar bajo modelos de series de tiempo es suponer que el futuro se comporta como el pasado. Eso solo tiene sentido si las propiedades de la serie no cambian en el tiempo.

Definición 1.1 (Estacionariedad débil)**.** Una serie y_t es estacionaria si para todo t:

$$E(y_t) = \mu, \qquad \text{Var}(y_t) = \sigma^2, \qquad \text{Cov}(y_t, y_{t-h}) = \gamma_h$$

Es decir, la media y la varianza son constantes, y la covarianza depende solo de la distancia h entre observaciones, no del momento t.

Definición 1.2 (Ruido blanco)**.** Es la serie estacionaria más simple:

$$y_t = \varepsilon_t, \qquad E(\varepsilon_t) = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \text{Cov}(\varepsilon_t, \varepsilon_{t-h}) = 0$$

Definición 1.3 (Random Walk)**.** Cada shock se suma al valor anterior y se queda para siempre:

$$y_t = y_{t-1} + \varepsilon_t = y_0 + \sum_{i=1}^{t} \varepsilon_i$$

Como $\text{Var}(y_t) = t\,\sigma^2$ crece con t, el Random Walk no es estacionario.

Definición 1.4 (Test de Dickey-Fuller aumentado, ADF)**.** Se estima

$$\Delta y_t = \alpha + \beta\, y_{t-1} + \sum_{i=1}^{k} \delta_i \Delta y_{t-i} + \varepsilon_t$$

y se contrasta:

- $H_0 : \beta = 0$ La serie tiene raíz unitaria (no es estacionaria).
- $H_1 : \beta < 0$ La serie es estacionaria.

Los rezagos Δy_{t-i} corresponden a la parte "aumentada", controlan la autocorrelación de los errores. Si el p-value es menor que 0.05, se rechaza H_0 y se concluye que la serie es estacionaria.[1]

*Universidad de Chile, Facultad de Economía y Negocios, `joamartine@fen.uchile.cl`

[1] Bajo H_0 el estadístico de β no sigue una distribución t, sino la distribución de Dickey-Fuller, cuyos valores críticos son más negativos. El p-value que entrega `adfuller` ya se calcula con esta distribución, por lo que basta compararlo con 0.05.

Código en R. Se simulan un ruido blanco y un Random Walk con los mismos shocks, se compara la media por tramos y se aplica el test ADF con `adf.test` del paquete `tseries`. Esta función incluye constante y tendencia en la regresión y elige el número de rezagos como $k = \lfloor (n-1)^{1/3} \rfloor$.

```
library(tseries)

set.seed(318)
n <- 500
eps <- rnorm(n)

ruido_blanco <- eps
random_walk <- cumsum(eps) # y_t = y_{t-1} + e_t

# Media en tres tramos de igual largo
tramo <- cut(1:n, breaks = 3, labels = FALSE)
print(round(tapply(ruido_blanco, tramo, mean), 2))
print(round(tapply(random_walk, tramo, mean), 2))

# Test ADF: H0 = raíz unitaria
# (p-value = 0.01 significa p < 0.01)
adf.test(ruido_blanco)
adf.test(random_walk)
```

```
    1     2     3
-0.12  0.09  0.03
     1      2      3
-15.64  -9.32  -1.54

        Augmented Dickey-Fuller Test

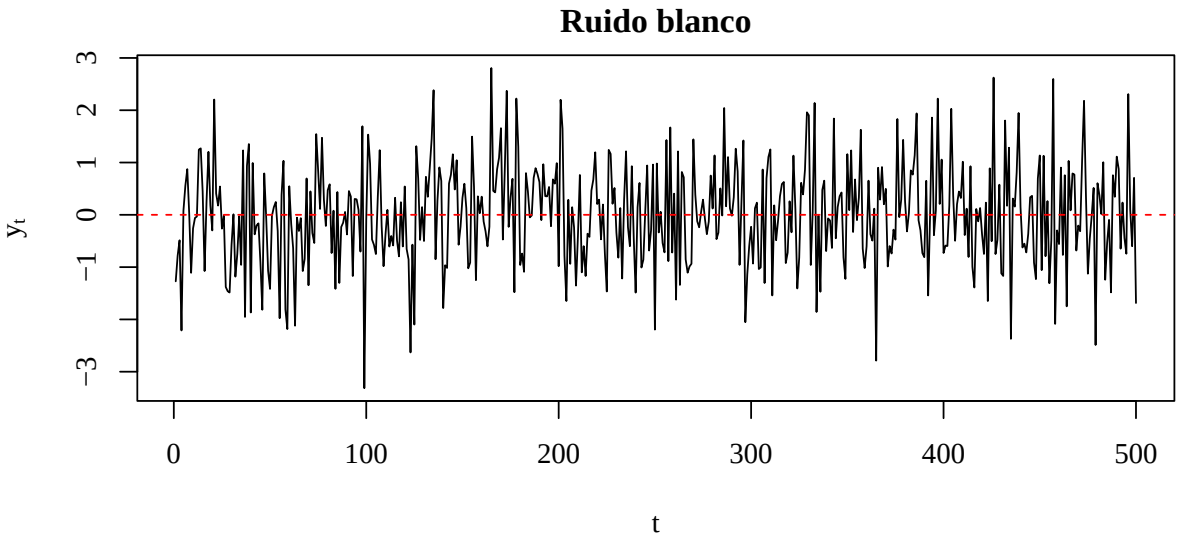
data:  ruido_blanco
Dickey-Fuller = -6.9125, Lag order = 7, p-value = 0.01
alternative hypothesis: stationary


        Augmented Dickey-Fuller Test

data:  random_walk
Dickey-Fuller = -2.6105, Lag order = 7, p-value = 0.3199
alternative hypothesis: stationary
```

El ruido blanco se grafica con `plot`, la línea roja marca su media teórica, igual a cero.

```
plot(ruido_blanco, type = "l", main = "Ruido blanco",
     xlab = "t", ylab = expression(y[t]))
abline(h = 0, col = "red", lty = 2)
```



2. Tendencia determinista vs. estocástica

Dos series pueden verse igual de similares y, aun así, necesitar tratamientos distintos.

Definición 2.1 (Tendencia determinista)**.** Una serie tiene tendencia determinista si fluctúa alrededor de una recta:

$$y_t = \alpha_0 + \delta t + \varepsilon_t$$

Un shock es transitorio pues al período siguiente la serie vuelve a la tendencia. Se trata quitando la tendencia.

Definición 2.2 (Tendencia estocástica)**.** Una serie tiene tendencia estocástica si sigue un Random Walk con drift:

$$y_t = \alpha_0 + y_{t-1} + \varepsilon_t$$

Un shock es permanente, cambia el nivel de la serie para siempre. Se trata diferenciando:

$$\Delta y_t = y_t - y_{t-1} = \alpha_0 + \varepsilon_t$$

que es estacionaria. Por eso se trabaja con retornos y no con precios.

	Determinista	Estocástica
Efecto de un shock	Transitorio	Permanente
Tratamiento	Quitar la tendencia	Diferenciar
Ejemplo	Contrato con reajuste fijo	Precio de una acción

Observación 2.3 (Sobrediferenciación)**.** Si se diferencia una serie con tendencia determinista, se obtiene

$$\Delta y_t = \delta + \varepsilon_t - \varepsilon_{t-1}$$

que es estacionaria, pero se le introduce un MA(1) artificial. Su señal es una autocorrelación cercana a -0.5 en el primer rezago.

Código en R. Se simulan ambas tendencias con el mismo shock en $t = 100$ y se aplica a cada una el tratamiento correcto y el incorrecto.

```
library(tseries)

set.seed(123)
n <- 250
t <- 1:n
eps <- rnorm(n)
shock <- rep(0, n); shock[100] <- 10 # shock de +10 en t = 100

y_det <- 0.05 * t + eps + shock # tendencia determinista
y_est <- cumsum(0.05 + eps + shock) # tendencia estocástica

# Quitar tendencia: residuos de la regresión sobre t
sin_tend_det <- residuals(lm(y_det ~ t))
sin_tend_est <- residuals(lm(y_est ~ t))

# p-value del test ADF
p_adf <- function(x) round(adf.test(x)$p.value, 4)

cat("Determinista sin tendencia:", p_adf(sin_tend_det), "\n")
cat("Determinista diferenciada: ", p_adf(diff(y_det)), "\n")
cat("Estocástica sin tendencia: ", p_adf(sin_tend_est), "\n")
cat("Estocástica diferenciada:  ", p_adf(diff(y_est)), "\n")

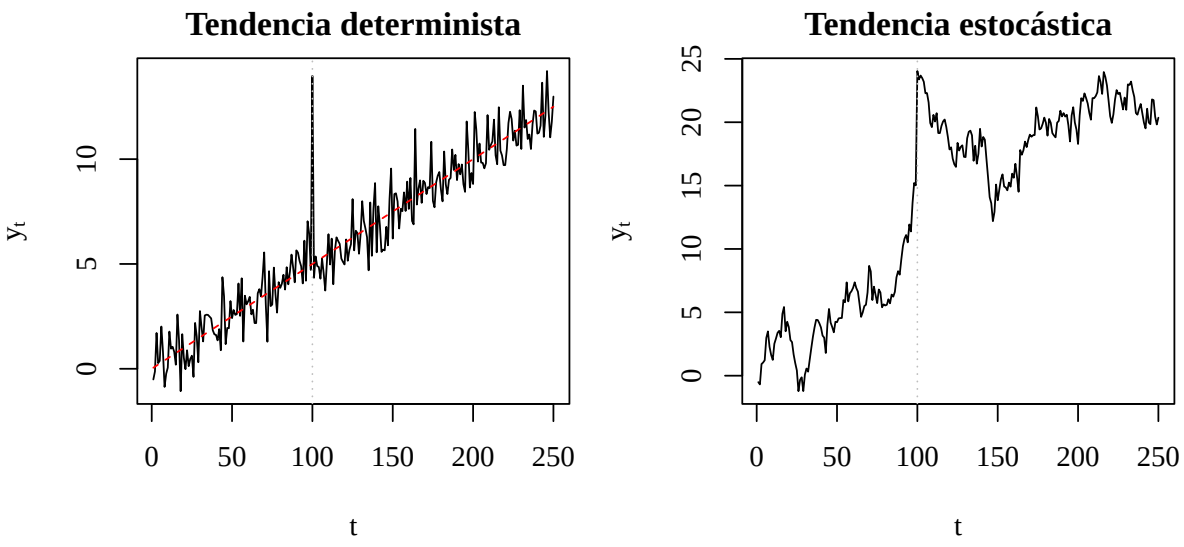
# Sobrediferenciación: ACF en el rezago 1
acf_1 <- acf(diff(y_det), plot = FALSE)$acf[2]
cat("ACF rezago 1 de diff(y_det):", round(acf_1, 2), "\n")
```

```
Determinista sin tendencia: 0.01
Determinista diferenciada:  0.01
Estocástica sin tendencia:  0.6047
Estocástica diferenciada:   0.01
ACF rezago 1 de diff(y_det): -0.53
```

En los gráficos, la línea punteada gris marca el shock en $t = 100$ y la línea roja la tendencia $0.05t$. En la serie determinista el shock dura un período, en la estocástica cambia el nivel para siempre.

```
par(mfrow = c(1, 2))
plot(t, y_det, type = "l", main = "Tendencia determinista",
     xlab = "t", ylab = expression(y[t]))
lines(t, 0.05 * t, col = "red", lty = 2)
abline(v = 100, col = "gray", lty = 3)

plot(t, y_est, type = "l", main = "Tendencia estocástica",
     xlab = "t", ylab = expression(y[t]))
abline(v = 100, col = "gray", lty = 3)
```



3. Procesos AR y MA

Definición 3.1 (Proceso autorregresivo, AR(p))**.** El valor de hoy depende de los valores pasados:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

El AR es la memoria del nivel. El AR(1), $y_t = c + \phi y_{t-1} + \varepsilon_t$, es estacionario si $|\phi| < 1$. Un shock se apaga de a poco, después de k períodos su efecto es ϕ^k.

Ejemplo 3.2. Si el inventario quedó alto este mes, el próximo mes también parte alto y se normaliza lentamente.

Definición 3.3 (Proceso de media móvil, MA(q))**.** El valor de hoy depende de los shocks pasados:

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

El MA es la memoria del shock. Un shock afecta solo q períodos y luego desaparece por completo. Los procesos MA siempre son estacionarios.

Definición 3.4 (Proceso ARMA(p, q))**.** Combina ambos:

$$y_t = c + \sum_{i=1}^{p} \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}$$

Definición 3.5 (ACF y PACF)**.**

- **ACF:** correlación entre y_t y y_{t-k}.
- **PACF:** correlación entre y_t y y_{t-k}, eliminando el efecto de los rezagos intermedios $y_{t-1}, \ldots, y_{t-k+1}$.

Estas funciones permiten identificar el tipo de proceso y su orden:

	ACF	PACF
AR(p)	Decae gradualmente	Se corta en el rezago p
MA(q)	Se corta en el rezago q	Decae gradualmente

Código en R. Se simulan un AR(1) y un MA(1) con `arima.sim` y se revisan sus primeros rezagos de ACF y PACF. Luego se estima el AR(1) con `arima`.

```
set.seed(318)
ar1 <- arima.sim(model = list(ar = 0.7), n = 250)
ma1 <- arima.sim(model = list(ma = 0.7), n = 250)

# Primeros 5 rezagos de ACF y PACF
cat("AR(1) ACF: ", round(acf(ar1, plot = FALSE)$acf[2:6], 2), "\n")
cat("AR(1) PACF:", round(pacf(ar1, plot = FALSE)$acf[1:5], 2), "\n")
cat("MA(1) ACF: ", round(acf(ma1, plot = FALSE)$acf[2:6], 2), "\n")
cat("MA(1) PACF:", round(pacf(ma1, plot = FALSE)$acf[1:5], 2), "\n")

# Estimación: se recupera el parámetro verdadero (0.7)
arima(ar1, order = c(1, 0, 0))
```

```
AR(1) ACF:  0.74 0.59 0.5 0.43 0.35
AR(1) PACF: 0.74 0.08 0.1 0.03 -0.04
MA(1) ACF:  0.38 -0.11 -0.11 -0.12 -0.04
MA(1) PACF: 0.38 -0.3 0.07 -0.17 0.08

Call:
arima(x = ar1, order = c(1, 0, 0))

Coefficients:
         ar1  intercept
      0.7456    -0.1285
s.e.  0.0421     0.2398

sigma^2 estimated as 0.9528:  log likelihood = -349.09,  aic = 704.19
```

4. Proyecciones: reversión a la media vs. SARIMA

Proposición 4.1 (Media de largo plazo de un AR(1))**.** Sea $y_t = c + \phi y_{t-1} + \varepsilon_t$ un AR(1) estacionario. Entonces su media es

$$\mu = \frac{c}{1-\phi}$$

Demostración. Por estacionariedad, $E(y_t) = E(y_{t-1}) = \mu$. Tomando esperanza en el modelo, $\mu = c + \phi\mu$, y despejando se obtiene el resultado. □

Proposición 4.2 (Reversión a la media)**.** El pronóstico a h períodos de un AR(1) estacionario es

$$\hat{y}_{T+h} = \mu + \phi^h (y_T - \mu)$$

Como $|\phi| < 1$, cuando h crece se tiene $\phi^h \to 0$ y el pronóstico converge a μ. Cuanto más lejos proyectamos, menos importa el último dato.

Definición 4.3 (Modelo SARIMA$(p,d,q) \times (P,D,Q)_m$)**.** Es un modelo ARIMA al que se le agrega una parte estacional:

- (p, d, q): parte regular (rezagos AR, diferencias y rezagos MA).
- (P, D, Q): lo mismo, pero en rezagos estacionales $(m, 2m, \dots)$.

- m: períodos por año ($m = 12$ en datos mensuales).

Definición 4.4 (Diferencia estacional)**.** Con $D = 1$, cada mes se compara con el mismo mes del año anterior:

$$\Delta_{12}\, y_t = y_t - y_{t-12}$$

Ejemplo 4.5. El SARIMA$(1,0,0) \times (1,1,0)_{12}$ es un AR(1) aplicado a $\Delta_{12} y_t$, más un rezago autorregresivo estacional.

Código en R. Con los datos de ventas de energía a clientes regulados (en TWh) se comparan los pronósticos a 24 meses de un AR(1) y de un SARIMA$(1,0,0) \times (1,1,0)_{12}$. Notar que en `arima` el coeficiente `intercept` es la media μ y no la constante c.

```
url <- paste0("https://raw.githubusercontent.com/victormaciase/",
              "EconometriaFinanciera_MagisterFinanzasWK/refs/heads/main/",
              "Lab11/ventas_energia.csv")
energia <- read.csv(url)
ventas <- ts(energia$regulado / 1e6, start = c(2019, 1), frequency = 12)

# Train: hasta junio 2024 | Test: últimos 24 meses
train <- window(ventas, end = c(2024, 6))
test <- window(ventas, start = c(2024, 7))

# Modelo 1: AR(1) sin estacionalidad
m_ar1 <- arima(train, order = c(1, 0, 0))
print(m_ar1)
cat("Media del train:", round(mean(train), 4), "\n")

# Modelo 2: SARIMA(1,0,0)x(1,1,0)_12
m_sarima <- arima(train, order = c(1, 0, 0),
                  seasonal = list(order = c(1, 1, 0), period = 12))
print(m_sarima)

# Pronóstico a 24 meses
pred_ar1 <- predict(m_ar1, n.ahead = 24)$pred
pred_sarima <- predict(m_sarima, n.ahead = 24)$pred
print(round(head(cbind(test, pred_ar1, pred_sarima), 6), 3))

# Métricas fuera de muestra
errores <- cbind("AR(1)" = test - pred_ar1, SARIMA = test - pred_sarima)
round(rbind(RMSE = sqrt(colMeans(errores^2)), MAE = colMeans(abs(errores))), 4)
```

```
Call:
arima(x = train, order = c(1, 0, 0))

Coefficients:
         ar1  intercept
      0.5389     2.5297
s.e.  0.1053     0.0426

sigma^2 estimated as 0.02617:  log likelihood = 26.4,  aic = -46.8
Media del train: 2.5223
```

```
Call:
arima(x = train, order = c(1, 0, 0), seasonal = list(order = c(1, 1, 0), period = 12))

Coefficients:
         ar1     sar1
      0.8303  -0.4283
s.e.  0.0738   0.1725

sigma^2 estimated as 0.009954:  log likelihood = 46.09,  aic = -86.17
          test pred_ar1 pred_sarima
Jul 2024 2.964    2.704       2.969
Aug 2024 2.737    2.624       2.802
Sep 2024 2.387    2.580       2.544
Oct 2024 2.404    2.557       2.466
Nov 2024 2.365    2.544       2.428
Dec 2024 2.562    2.538       2.601
      AR(1) SARIMA
RMSE 0.1801 0.0893
MAE  0.1578 0.0719
```